


데이터 분석 프로젝트

장바구니에 담은 상품의 7일 내 구매 여부 분류

담기 전 행동이 구매를 얼마나 설명하는가

화장품 온라인 스토어 행동 기록 약 874만 건 분석

이슬기 · 배지환 | 2026. 09. 12



CONTENTS

목차

I 프로젝트 개요

배경과 목적 · 연구 질문과 프로세스 · 데이터와 품질 점검 · 분석 대상 확정

II 탐색적 데이터 분석

단변량 · 목표변수와의 관계 · 변수 선택

III 모델링

모델링용 전처리 · 모형 설계와 가정 · 평가 기준 · 개선과 비교

IV 분석 결과

모형의 신뢰성 · 변수 영향력

V 결론

질문별 답변 · 의의와 시사점 · 한계

참고자료

데이터 · 분석 도구 · 산출물

01

1. 프로젝트 개요

1-1 분석 배경과 목적

1-2 연구 질문과 분석 프로세스


1-3 데이터 품질 점검

1-4 분석 대상 확정

문제 정의 — 담은 상품이 왜 구매로 이어지지 않는가

품질 점검 후 행동 로그 826만 건의 구성

(원본 874만 건에서 중복·무효값 제거)



문제 정의

장바구니에 담은 행동은 **살 의향**이 있다는 신호다.

살 의향을 한 번 드러낸 고객이 멈춘 지점이기 때문에
개선 여지가 가장 크다고 보았다.

문제는 어디에서 멈추는지 알 수 없다는 것이다.

담는 시점에 알 수 있는 조건 → 가격 · 브랜드 · 담기 직전 행동 가운데
무엇이 구매 여부와 가장 크게 연관되는지 확인한다.

이 결과는 스토어의 상품 진열 · 가격 정책 담당자가
“담기까지는 왔지만 사지는 않는 구간”을 좁히는 데 사용한다.

위 그래프는 중복 기록과 무효값을 건어낸 값이다.

담기 취소는 원본의 24.2%가 중복이고 다른 이벤트는 2% 미만이라, 취소 행동을 해석에 참고할 때는 이 점을 감안해야 한다.)

담기 249만 건과 구매 57만 건은 서로 다른 고객·다른 상품의 이벤트 수이므로 나눠서 전환율로 읽지 않는다.

분석 설계 — 고객 1명의 7일 내 구매 여부 = 1행

핵심 질문 장바구니에 담은 시점에 알 수 있는 정보만으로 담은 그 상품의 7일 내 구매 여부를 얼마나 분류할 수 있으며, 그 분류에 가장 크게 기여하는 조건은 무엇인가?

문제 유형 — 분류 → 두 집단(구매 / 미구매) 가운데 어디에 속하는지



목표변수 — 7일 내 구매 여부(purchase_7d) → 담은 그 상품을 7일 내 구매하면 1, 아니면 0

관측 단위 — 고객 1명 = 1행. 고객별 최초 담기 1건만 사용

사용자 — 스토어의 상품 진열 · 가격 정책 담당자와 고객 대상 마케팅(CRM) 담당자

처음 가정 — 조회 행동이 구매 전환에 영향을 미친다 → 결론에서 검토 예정

분석 프로세스 — 주제 선정에서 결론까지



행동 로그 874만 행을 고객 108,458행으로 바꾸고, 후보 변수 8개 중 6개를 골라 모형을 세웠다.

데이터 소개 — 한 행은 행동 하나

출처	Kaggle 공개 데이터셋 (제공 REES46 Marketing Platform)
규모	8,738,120행 × 9열
기간	2019-10-01 ~ 2019-11-30
파일	월별 5개 중 2개 사용
대상 범위	화장품 온라인 스토어 한 곳에 한함

한 행은 누가 · 언제 · 어떤 상품에 · 무엇을 했다”는 행동 기록 하나

고객 한 사람이 평균 11.6건, 많게는 8,628건 기록을 남긴다.

그래서 이 표에서는 한 줄이 한 사람을 뜻하지 않는다.

분석 단위는 고객이므로, 고객 1명이 1행이 되도록 다시 만든다.

변수	의미	척도	비고
user_id	고객 식별자	명목	고객 1명 = 1행의 기준
user_session	세션 식별자	명목	정의가 불안정해 쓰지 않는다
event_time	행동 시각	등간	UTC 표기 — 시간대를 보정해 사용
event_type	행동 종류	명목	4종 — 조회 · 담기 · 담기 취소 · 구매
product_id	상품 식별자	명목	"담은 그 상품"을 정의하는 기준
category_id	품목 식별자	명목	통제 변수로 쓰지 못해 제외
category_code	품목 이름	명목	결측 98.32%이므로 사용하지 않는다
brand	브랜드	명목	결측 41.69% → '미상'을 범주로 유지
price	담긴 시점의 가격	비율	통화 표기 없음 → 상대 비교에만 사용

공개 페이지 설명은 “대형 종합몰”이나 실제 브랜드는 네일·뷰티 계열뿐, 품목 이름 컬럼은 98.32%가 비어 있고 남은 2%마저 진공청소기·문구·장갑 등 이 스토어와 무관한 값이었다.

다른 데이터셋의 설명을 옮겨 붙인 것으로 보여, 파일을 직접 열어 확인한 내용만 근거로 삼았다.



품질 점검 — 중복값·오류·결측치 처리 및 시각 3시간 보정

점검	결과	처리
완전 중복	459,848행 (5.26%)	고객 · 상품 · 행동 · 시각 네 컬럼 기준으로 461,449행 제거(차이 1,601행 전부 세션 번호만 다른 행)
가격 0 이하 (중복 제거 후 기준)	17,512행 (0.212%)	음수 36 · 0인 행 17,476. 기록 오류로 보고 제외
품목 이름 결측	98.32%	컬럼 전체를 사용하지 않음. 남은 2%도 화장품 스토어와 무관한 값뿐
브랜드 결측	41.69%	'미상'을 하나의 범주로 유지 — 기록되지 않았다는 것 자체가 정보일 수 있음

중복 기준을 완전 중복이 아니라 네 컬럼으로 넓혔다.

목표변수는 중복이 남아도 값이 바뀌지 않지만, 세는 설명변수는 같은 조회가 세 번 기록되면 값이 부풀려진다.

남은 8,259,159행을 다음 단계에서 고객 단위로 바꾼다.



시각 보정 UTC → UTC+3

활동 최저 새벽 1시 → 새벽 4시

활동 최고 저녁 7시 → 밤 10시

+3을 고른 근거 → 공개자와 브랜드 구성이 러시아·CIS를 가리킨다 (모스크바 시간 = UTC+3)
담은 시각과 요일을 설명변수로 쓰므로, 어긋난 채 두면 해석이 달라진다.

시간대는 제공처가 밝힌 문서가 없어 활동 분포의 모양으로 추정했다. 곡선만으로는 +2와 +3을 가르지 못하나, 담은 시각을 네 구간으로 묶으므로 1시간 차이는 대부분 같은 구간에 떨어진다. 한계에 함께 적었다.

관측 창 — 세션 대신 담기 직전 30분간을 기준으로 설정

세션을 기각한 근거

세션 사이 간격 1분 미만

33.0%

한 번의 방문이 여러 세션으로 쪼개진다

세션 지속 24시간 초과

0.6%

여러 날의 활동이 한 세션으로 묶인다 (최장 60.7일)

두 방향으로 동시에 어긋난다.

같은 사람이 같은 상품을 같은 초에 조회했는데,

세션 번호만 갈린 행도 1,601건 있었다.

그래서 분석 단위로도, 변수의 재료로도 쓰지 않는다.

대신 고객 · 상품 · 시간 창으로 직접 정의했다

창 길이	5분	10분	30분	60분	180분
담기 직전 행동이 창 안에 들어오는 비율	92.8%	95.4%	96.8%	97.2%	97.6%
조회 없는 담기 비율	48.6%	38.8%	30.4%	28.3%	26.4%

30분이면 담기 직전 행동의 96.8%가 들어오고, 60분으로 늘려도 0.4%p밖에 더 얻지 못한다. 조회 없는 담기 비율도 2.1%p만 움직인다.


미리 정한 규칙대로, 증가가 완만해지는 첫 지점인 30분으로 확정했다.

결과를 보기 전에 정한 것은 창 길이가 아니라 판단 규칙이다 — "창을 늘려도 담기 직전 행동의 포함 비율이 거의 늘지 않는 첫 지점을 고르고, 고른 뒤에는 바꾸지 않는다."

위 표는 전체 담기 이벤트 기준(담기 1건 = 1행)이며, 최종 분석 대상(고객별 최초 담기 1건)에서는 조회 기록이 없는 고객이 44.7%다. 설명변수는 담은 시각(t_0)까지의 기록만 쓴다($t_0 - 30\text{분} \leq \text{조회} \leq t_0$). 기록이 초 단위라 상품을 보고 바로 담으면 조회와 담기가 같은 초에 찍히므로, t_0 와 같은 초의 조회도 포함한다 — 담은 뒤가 아니라 담은 순간의 행동이다.

목표변수 — “7일 내 구매 여부” 정의가 놓친 두 지점

7일 내 구매 여부(purchase_7d) 최초 담기 시각(t_0)부터 7일 안에
같은 고객이 같은 상품을 구매하면 1, 아니면 0



[그림] 담은 뒤 구매까지 걸린 시간 — 7일 내 구매 22,236명 기준 누적 비율

7일 내 구매 22,236명 중 63.57%가 담은 지 1시간 안에, 94.59%가 3일 안에 구매했다.

창을 더 늘리면 관측 종료 직전 구간을 그만큼 더 잘라내야 해서 분석 대상이 줄어든다. 그래서 7일로 끊었다.


① 다른 상품으로 갈아탄 고객 (담은 뒤 7일 내 다른 상품 구매)

	다른 상품 구매 없음	다른 상품 구매 있음	합계
미구매 (0)	79,762 (92.51%)	6,460 (7.49%)	86,222
구매 (1)	3,031 (13.63%)	19,205 (86.37%)	22,236

미구매로 기록된 고객의 92.51%는 담은 뒤 7일 안에 다른 상품도 사지 않았다.
나머지 7.49%는 같은 기간에 다른 상품을 샀다 — 대체 구매일 가능성이 있다.

② 7일을 넘겨 구매한 고객

담은 그 상품을 결국 구매한 고객은 24,109명이다. 이 가운데 7일 안에 산 22,236명만 구매(1)가 되고, 나머지 1,873명(7.77%)은 7일이 지난 뒤에 사서 미구매(0)로 기록된다.




**그래서 결론에서 "사지 않았다"가 아니라
"담은 그 상품을 사지 않았다"로 적는다.**

이 비율에는 낮음·높음의 경계값을 두지 않았다. 대신 산출 전에 "값을 그대로 인용하고 두 해석을 함께 적는다"고 정했다 — 대부분은 아무것도 사지 않았으므로 이탤로 읽는 통상적 해석이 대체로 유효하고, 일부는 다른 상품을 샀으므로 이 분석의 답은 "담은 그 상품의 구매 여부"로 한정한다.

경계 규칙은 담은 순간은 빼고 7일째까지 포함($t_0 < \text{구매시각} \leq t_0 + 7\text{일}$)이며, t_0 와 같은 초의 구매는 0건이라 표본에 영향을 주지 않았다. 위 곡선은 분모가 7일 내 구매자이므로 7일 지점이 100%인 것은 정의상 당연하며, 그 이후는 이 곡선이 말해주지 않는다.

표본 축소 — 세 단계 제외 후 108,458명



[그림] 일별 첫 담기 인원 — 10월 11일부터 평상시 수준으로 내려온다. 붉은 구간이 제외 구간이다 (관측 종료일 11월 24일은 3시간분뿐이라 표시하지 않았다)

잘라낸 구간	이유	제외	남은 인원
담은 고객 전체	—	—	210,593명
관측 종료 직전 담기	7일을 다 볼 수 없다	19,668명 (9.34%)	190,925명
관측 초기 구간	첫 담기가 실제로는 최초가 아니다	82,295명 (43.10%)	108,630명
같은 초 복수 상품	어느 것을 최초로 볼지 정할 근거가 없다	172명 (0.16%)	108,458명

(가) 결정 기준

경계는 일별 담기 인원이 평상시 수준으로 내려오는 첫날인 2019년 10월 11일로 먼저 정했다. 이 기준은 목표변수와 무관하다.

(나) 사후 확인

정한 뒤 확인하니, 주별 구매 비율은 7.79% → 12.30% → 20.39%로 오른 뒤, 담기 전 조회 보유율은 83.58% → 55%대로 내려간 뒤 평평해졌다. 경계를 10월 8일~15일 중 어느 날로 잡아도 구매 비율은 20.05~20.52%로 결론이 흔들리지 않는다.

(다) 제외 집단 점검 — 보류

빠지는 고객이 원래 활발한 고객인지 보려고, 담은 뒤 7일 안에 다시 담은 고객 비율(재담기율)을 비교했다. 첫 주 89.28% vs 평상시 78.10% = 1.14배로, 사전 기준(1.3 이상 지지 / 1.1 미만 기각)에서 ‘보류’였다. 활발한 고객을 덜어냈다고 단정할 수도 배제할 수도 없어 한계에 적었다(p.41).

각 제외 비율은 그 단계에서 남아 있던 인원 기준이다.

구간 제외 전후 — 조회와 구매 관계의 역전

담기 전 조회 횟수	0회	1회	2회	3회	4~5회	6~10회	11회 이상
초기 구간 제외 전 구매 비율	18.87%	10.13%	22.43%	22.41%	21.95%	23.48%	26.49%
초기 구간 제외 후 구매 비율	18.54%	21.67%	22.66%	21.85%	22.31%	22.99%	25.71%

초기 구간 제외 전 → 후

제외 후에는 조회할수록 더 사는 방향으로 정리된다.


제외 전에는 조회를 한 번 한 사람(10.13%)이 아예 안 한 사람(18.87%)보다 덜 사는 이상한 모양이었다.
이 역전은 관측 초기 구간이 섞여서 생긴 모양이다.

관측 시작 이전부터 이용하던 고객의 기록상 첫 담기가 초반에 한꺼번에 잡히면서 만들어졌다.

구매 비율	15.36%	→	20.50%
분석 대상	190,698명 (같은 초 복수 상품 제외 후)	→	108,458명
조회 유무 관계	조회 없음이 더 구매	→	조회할수록 더 산다

중간 역전 폭이 1.0%p 이하면 표본 흔들림으로 본다는 기준은 결과를 보기 전에 정했고, 제외 후 2회(22.66%) → 3회(21.85%)의 0.81%p가 그 안에 든다.

표본 확정 — 108,458명과 목표변수 3층 검증



[그림] 분석 대상 축소 경위

최종 분석 대상

108,458명

1행 = 고객 1명

구매 (Y = 1)

22,236명

20.50%

Y 검증 3층 — 세 층이 각각 다른 실패를 잡는다

층	대상	무엇을 잡는가	결과
수기 대조	20명	규칙 해석 자체의 오류	이상 없음
정합성 검증	7종	값·관계가 규칙과 어긋나는 경우	전부 통과
전수 재계산	108,458명	코드가 규칙대로 돌지 않은 경우	전 항목 통과

한 층만으로는 빈틈이 남는다

전수 재계산은 목표변수를 만들 때와 같은 규칙 해석에 기대므로 "규칙을 잘못 읽었을 가능성"을 잡지 못한다. 반대로 수기 대조 20명은 드문 경계 사례를 놓친다.

정합성 검증 7종 — ① 그 상품 조회 ≤ 전체 조회 ② 조회 상품 종류 수 ≤ 전체 조회 ③ 조회가 있으면 종류 ≥ 1 ④ 조회 여부와 조회 횟수의 일치 ⑤ 구매(1)의 시차 0~168시간 ⑥ 미구매(0)는 시차 없음 ⑦ 가격 전부 양수
2인 교차 검수 — 설명변수를 만든 사람과 수기 대조를 한 사람을 다르게 두었다.

02


2. 탐색적 데이터 분석

2-1 단변량

2-2 목표변수와의 관계

2-3 변수 선택

단변량 분포 — 담기 전 행동 변수의 0이 44.7% · 61.3%



연속형	평균	중앙값	왜도	0인 비율
담긴 시점의 가격 (price)	10.140	5.1	7.21	0.0%
담기 직전 30분의 전체 조회 횟수 (prior_view_cnt)	1.280	1.0	5.90	44.7%
담기 직전 30분에 본 상품 종류 수 (prior_uniq_product_cnt) — (p.18에서 제외)	1.120	1.0	6.04	44.7%
담기 직전 30분에 그 상품을 본 횟수 (cart_product_view_cnt)	0.458	0.0	1.75	61.3%

명목형	구성
담은 시간대 (cart_timeband)	심야 0~5시 · 오전 6~11시 · 오후 12~17시 · 저녁 18~23시 (UTC+3 기준)
담은 요일 (cart_weekday)	월 14.34 · 화 13.58 · 수 13.61 · 목 14.71 금 16.81 · 토 14.06 · 일 12.89 (%)
브랜드 묶음 (brand_grp)	미상 38.85 · 기타 23.63 · runail 6.22 irisk 5.03 · grattol 4.37 · 이하 10종 (%)
담기 직전 30분의 조회 여부 (has_prior_view)	있음 55.3 · 없음 44.7 (%)

담기 전 행동 변수는 값의 절반 가까이가 0이다.

담기 직전 30분에 아무것도 보지 않은 고객이 44.7%,
담은 그 상품을 보지 않은 고객이 61.3%다.

이 두 수치는 뒤에서 예측력의 한계를 설명할 때 다시 쓴다.

로그 변환 — 왜도 자체는 로지스틱 회귀의 가정이 아니지만, 소수의 극단값(조회 최대 71회 · 가격 327.78)이 계수를 좌우하는 것을 줄이기 위해 |왜도| ≥ 1.0이면 변환한다는 기준을 결과를 보기 전에 정했다. 연속형 네 변수 모두 이 기준을 넘어 전처리 단계에서 변환 대상이 된다.

요일 분포를 그대로 읽지 않는다 — 대상 기간이 45일(6주 + 사흘)이라 금·토·일만 일곱 번 온다. 일평균으로 다시 보면 월 2,593 · 화 2,455 · 수 2,460 · 목 2,659 · 금 2,605 · 토 2,178 · 일 2,289명으로, 금요일이 특별히 많지 않고 주말이 평일보다 낮다. (관측 마지막 날인 11월 24일은 3시간분뿐이라 일요일 평균에서 제외했다.)

이변량 검정 — 여덟 변수 모두 “무시할 수준”의 효과크기

변수	검정	구매 / 미구매	효과크기	판정
담기 직전 30분에 그 상품을 본 횟수 (cart_product_view_cnt)	Mann-Whitney U	0.5725 / 0.4289 (+33%)	η^2 0.00776	무시할 수준
담기 직전 30분의 전체 조회 횟수 (prior_view_cnt)	Mann-Whitney U	1.4262 / 1.2420	η^2 0.00100	무시할 수준
담기 직전 30분에 본 상품 종류 수 (prior_uniq_product_cnt)	Mann-Whitney U	1.2258 / 1.0926	η^2 0.00073	무시할 수준
담긴 시점의 가격 (price)	Mann-Whitney U	11.295 / 9.842	η^2 0.00080	무시할 수준
담기 직전 30분의 조회 여부 (has_prior_view)	교차분석	22.09% / 18.54%	3.55%p 차	무시할 수준
브랜드 묶음 (brand_grp)	교차분석	12.09% ~ 28.46%	Cramér's V 0.0608	무시할 수준
담은 시간대 (cart_timeband)	교차분석	17.78% ~ 21.80%	Cramér's V 0.0303	무시할 수준
담은 요일 (cart_weekday)	교차분석	18.98% ~ 21.52%	Cramér's V 0.0215	무시할 수준

여덟 변수가 전부 유의($p < 0.0001$)했지만 효과크기는 전부 무시할 수준이었다.


표본이 10만 명대면 아주 작은 차이도 유의해지므로, 유의성으로는 변수 사이가 갈리지 않는다. 그래서 유의성으로 변수를 자르지 않았다.

검정 선택 — 목표변수가 범주형 2집단이므로 연속형 설명변수는 역할을 바꿔 두 집단 비교를, 명목형은 교차분석을 쓰고 상관분석은 쓰지 않는다. 정규성이 충족되지 않으면 비모수로 바꾸기로 사전에 정했고, 표본이 10만 명대라 네 변수 모두 기각되어 Mann-Whitney U를 적용했다.

효과크기 — 검정은 순위로 했으나 효과크기 η^2_p 는 평균 차이 기반(ANOVA 계열, 등분산 미충족 시 Welch 분기)이라 검정과 기준이 다르다. 판정선은 Cohen(1988)의 관례값 η^2_p 0.01 / 0.06 / 0.14와 Cramér's V 0.1 / 0.3 / 0.5를 그대로 써서, 각각 0.01 · 0.1 미만을 "무시할 수준"으로 적었다. 효과크기는 산출·보고와 같은 종류끼리의 비교에만 쓰고 채택·제외의 절단선으로는 쓰지 않았다 — 변수를 자른 근거는 중복뿐이다(p.18).

공통 눈금 — 구간별 구매 비율 폭, 최대 16.37%p

변수	구간별 구매 비율의 폭	단조성
브랜드 묶음 (brand_grp)	16.37%p	—
담기 직전 30분에 그 상품을 본 횟수 (cart_product_view_cnt)	10.44%p	단조 ↑
담긴 시점의 가격 (price)	10.10%p	단조 ↑
담기 직전 30분의 전체 조회 횟수 (prior_view_cnt)	7.17%p	단조 ↑ (허용폭 1%p)
담은 시간대 (cart_timeband)	4.02%p	—
담기 직전 30분에 본 상품 종류 수 (prior_uniq_product_cnt)	3.76%p	비단조
담기 직전 30분의 조회 여부 (has_prior_view)	3.55%p	—
담은 요일 (cart_weekday)	2.54%p	—



[그림] 구간별 구매 비율 — 점선은 전체 평균 20.50%

효과크기 지표는 척도마다 달라 나란히 비교할 수 없다. 그래서 모든 변수를 구간으로 나눈 뒤 “구간별 구매 비율의 최대 – 최소”라는 하나의 자로 다시 잴다.

그 상품 조회수는 0회 17.74% → 4회 이상 34.73%, 가격은 16.48% → 26.58%로 **중간에 뒤집히는 곳이 없다**. 이 단조성이 뒤에서 변수 영향력을 해석하는 근거가 된다.

구간 경계는 결과를 보기 전에 고정했고, 표본이 1,000명 미만인 구간은 제외했다. 경계는 목표변수와 무관한 다른 분석(관측 초기 구간 진단)에서 이미 확정된 것을 재사용해, 결과를 보고 경계를 고른 것이 아님을 확보했다.

이 필터에서 구간이 빠지는 변수는 그 상품 조회 횟수(5구간 중 3)와 상품 종류 수(7 중 6)뿐이며, 전 구간으로 계산하면 그 상품 조회 횟수가 16.99%p로 브랜드를 앞선다.

(이 자는 구간 개수에 영향을 받는다. 성격이 비슷한 변수끼리의 상대 비교에만 쓰고 절대 크기 판정에는 쓰지 않는다.)

변수 선택 — 여덟에서 여섯으로, 근거는 중복뿐

변수끼리 겹치는가		제외한 변수	근거
전체 조회 횟수 ↔ 조회 상품 종류 수 상관	0.9881		
두 변수의 분산팽창계수	20.218 / 19.995	담기 직전 30분에 본 상품 종류 수 (prior_uniq_product_cnt)	전체 조회 횟수와 사실상 같은 것을 가리킨다. 분산팽창계수가 거의 같아 어느 쪽을 뺄지 정해주지 못하므로, 구간별 폭이 더 크고(7.17 vs 3.76%p) 뒤집히지 않는 전체 조회 횟수를 남겼다
조회 여부 ↔ 전체 조회 횟수	완전 종속	담기 직전 30분의 조회 여부 (has_prior_view)	전체 조회 횟수에 포함되는 변수. “봤는가”보다 “몇 번 봤는가”가 정보를 더 담는지 비교해 후자를 남겼다
그 상품 조회 C 전체 조회 (포함 관계) · 상관 0.688	둘 다 남김		

여덟 변수 전부 효과크기가 무시할 수준이었으므로, 효과가 작다는 이유로 자르는 것은 무의미했다. 실제로 자른 근거는 “다른 변수와 중복된다” 하나뿐이다.

분산팽창계수 최대 20.218 → 1.249로 해소되었다 (수치형 5종 → 3종 기준. 더미 26열 기준은 p.21).

그 상품 조회 횟수도 전체 조회 횟수에 포함되지만, 상관이 0.688로 낮아 둘 다 남겼다.

▶ 최종 설명변수 6종 : 담긴 시점의 가격 · 담기 직전 30분의 전체 조회 횟수 · 담기 직전 30분에 그 상품을 본 횟수 · 브랜드 묶음 · 담은 시간대 · 담은 요일

두 번째 판단은 0.49%p 차이로 갈렸다 — “봤는가”로 얻는 정보 3.55%p, “몇 번 봤는가”로 더 얻는 정보 4.04%p. 표본이 조금만 달랐다면 반대로 결정될 수 있었던 판단이라 한계에 적었다.

품목 묶음(category_grp)을 모형에서 뺀 근거는 다음 장에서 따로 다룬다. 두 조회 변수를 모두 남긴 결과, 모형 안에서 전체 조회 횟수는 “그 상품 조회를 고정한 뒤의 그 밖의 조회”로 읽힌다(p.32).

03

3. 모델링


3-1 모델링용 전처리

3-2 모형 설계와 가정 검정

3-3 평가 기준

3-4 개선과 비교

누수 차단 — 분할 우선, 표준화 제외



구분	고객 수	구매	구매 비율
전체	108,458	22,236	20.5019%
학습용 (80%)	86,766	17,789	20.5023%
검증용 (20%)	21,692	4,447	20.5006%

하지 않은 것	이유
표준화	표준화 계수는 원단위 적합에서 직접 계산할 수 있다(p.31 · p.34). 미리 표준화 하면 계수가 ‘표준편차 단위의 로그 가격’이 되어 해석이 두 겹으로 멀어진다
불균형 보정	표본을 인위로 늘리거나 가중치를 주면 계수와 오즈비가 실제 값이 아니게 된다

세 비율이 소수 둘째 자리까지 일치한다.

분할을 가장 먼저 한 것은 학습용 정보가 검증용으로 새지 않게 하기 위해서다.

누수 등급 — 로그 변환은 행 단위라 안전, 더미는 학습용 열 기준에 맞춰야 하고, 스케일링·구간화·결측 대체는 학습용 통계를 쓰므로 분할 뒤에만 가능하다. · 불균형은 총화 추출 · 지표 병행 판독 · 기준값 조절로 대응했다.

변수 변환 — 치우침 보정과 기준 범주 교체

변수	변환	왜도 (전 → 후, 학습용)	변수	기본값 (이름 순 첫 범주)	지정값
담긴 시점의 가격 (price)	log	7.246 → 0.041	브랜드 묶음 (brand_grp)	bpw.style (1.92%)	runail (6.24%)
담기 직전 30분의 전체 조회 횟수 (prior_view_cnt)	log1p	5.829 → 1.043	담은 시간대 (cart_timeband)	심야 (8.45%)	심야 (동일)
담기 직전 30분에 그 상품을 본 횟수 (cart_product_view_cnt)	log1p	1.745 → 0.811	담은 요일 (cart_weekday)	금 (16.82%)	월 (14.36%)

범주를 펼치면 하나가 ‘기준’으로 빠지고 나머지를 그 기준과 비교하게 되는데, 기본 설정이면 이름 순으로 첫 범주가 기준이 된다. 브랜드에서는 그것이 15종 중 12번째 규모이자 **구매 비율이 12.09%로 가장 낮았던 극단 범주**여서, 모든 브랜드 계수가 최저 범주 대비로 읽히고 비교의 정밀도도 떨어진다.

그래서 기준을 직접 지정했다. 선정 규칙은 표본 크기와 범주의 순서 정의뿐이며 목표변수와 무관하다.

전처리 결과

설명변수	6종 → 26열
분산팽창계수 최대 (더미 26열)	4.4815
변수당 사건 수	684

기준을 바꿔도 모형은 동일하다 — 적합값·판별력·다른 변수의 계수와 p값이 전부 그대로이고, 바뀌는 것은 더미 계수를 "무엇 대비"로 읽느냐뿐이다. 0을 포함하는 변수에는 log1p, 최솟값 0.05로 0을 포함하지 않는 가격에는 log를 적용했다. · 전체 조회 횟수는 변환 뒤에도 왜도 1.043으로 사전 기준(|왜도| ≥ 1.0)을 넘는데, 조회 건수의 꼬리가 실제로 길어(최대 71회) 단조변환으로는 없앨 수 없다. · 이 장의 왜도와 범주 비중은 학습용 86,766명 기준이라 단변량 분포 장(전체 108,458명 기준)과 소수점이 다르다. · 변수당 사건 수는 학습용 기준(17,789 ÷ 26)이며 통상 기준은 10이다. · 검증용 데이터는 학습용의 열 목록에 맞췄다.

기준 모형 — 예측이 아닌 계수 해석

이 장에서 모형을 적합하는 목적은 예측 정확도를 높이는 데 있지 않다.

답는 시점의 어떤 조건이 구매 여부와 어떤 방향으로 얼마만큼 연결되는지를 계수와 오즈비로 읽는 것이 목적이고, 예측 성능은 그 계수를 신뢰할 수 있는지 판단하는 재료로 쓴다.

항목	기준 모형 (26열)	최종 모형 (28열)
모형 전체 유의성 (우도비 χ^2)	1,413.3 · p < 0.001	1,454.2 · p < 0.001
Pseudo R ² (McFadden)	0.0161	0.0165
AIC · Log-Likelihood	86,671.24 · -43,308.62	86,634.33 · -43,288.17
관측치 · 회귀항	86,766 · 26열 + 상수항	86,766 · 28열 + 상수항

후진소거법을 쓰지 않았다.

표본이 86,766명이라 계수가 아주 작아도 유의해지므로 유의성이 변수 사이를 갈라 주지 못한다. 효과크기 역시 여덟 변수 모두 ‘무시할 수준’으로 서로 구분되지 않는다(p.16).

어느 쪽을 먼저 뺄지 정할 근거가 되지 못한다.

모형 전체는 통계적으로 유의하나 적합도 지표는 낮다. 이 낮음의 원인은 IV의 학습곡선 판정에서 다룬다

로지스틱 회귀 — 이진 목표변수에 쓰는 회귀 모형. 계수는 로그 오즈의 변화량이고, 지수를 취하면 오즈비가 된다.
기준 모형은 곡선 항을 넣기 전 26열, 최종 모형은 곡선 항 2개를 포함한 28열이다. 곡선 항을 넣은 뒤 AIC가 36.91 줄었고, 검증용 ROC-AUC는 각각 0.5827 · 0.5841이다.

가정 검증 — 로짓 선형성 위배와 곡선 항 처방

가정 검증 — 로짓 선형성 (Box-Tidwell)

변수	p	판정
담기 직전 30분의 전체 조회 횟수 (prior_view_cnt)	< 0.001	위배 → 처방
담기 직전 30분에 그 상품을 본 횟수 (cart_product_view_cnt)	0.1755	유지
담긴 시점의 가격 (price)	0.7036	유지

처방 — 곡선 항을 넣고 라운드마다 재검정

라운드	결과
1	전체 조회 횟수에 곡선 항 채택 — AIC 86,671.24 → 86,643.41
2	그 상품 조회 횟수에 곡선 항 채택 (1라운드 뒤 재검정에서 새로 걸림) — AIC 86,643.41 → 86,634.33
3	위배 없음 → 종료

판정 규칙은 결과보다 먼저 정했다. 진입 전에 대비한 변수는 그 상품 조회수였으나, 실제 위배는 전체 조회 횟수에서 났다.

다만 전체 조회 횟수도 로그 변환 뒤에 치우침이 남아 직선성 확인 대상에 넣어 두었고, 위배 시의 처방도 곡선 항과 구간화 두 갈래로 나눠 두었다. 그래서 예상이 빗나간 지점에서 기준을 새로 만들 필요가 없었다.

곡선 항으로 해소되었으므로 구간화하지 않았다. 표본이 크면 작은 곡률도 유의해지므로 p값만으로 채택하지 않고 실제 개선도 함께 확인했다 — AIC 36.91 감소, 검증용 ROC-AUC 0.5827 → 0.5841(+0.0014).

설명변수 열 수

26 → 28

곡선 항 2개 추가

위배 0건 · 분산팽창계수 최대 4.482 (더미 26열)

로짓 선형성 — 설명변수와 로그 오즈의 관계가 직선인가. 로지스틱 회귀의 가정 셋(직선성 · 다중공선성 · 독립성) 중 하나이며, 정규성과 등분산성은 이 모형의 가정이 아니다.

독립성은 설계로 확보했다 — 고객당 최초 담기 1건만 남겨 한 행이 고객 하나가 되므로 관측치 사이에 겹치는 구조가 없다. · 검증용에는 학습용에서 구한 중심값을 그대로 재사용했다. 검증용에서 다시 계산하면 정보 누수가 일어난다.

지표와 판정선 — 사전 확정된 7개 항목

항목	확정 내용	확정 시점
주 지표	ROC-AUC	목표변수 생성 직후
보조 지표	F1 · 정밀도 · 재현율 · PR-AUC	같음
분기 규칙	양성 비율이 10% 미만이면 PR-AUC로 전환 → 실제 20.50%라 ROC-AUC 유지	계획 단계
기준값 선정	학습용에서만 F1이 최대가 되는 값을 찾는다	모델링 진입 전
과적합 판정	학습용과 교차검증의 격차 15% 이상 또는 AUC 절대차 0.01 이상	모델링 진입 전
과소적합 판정	학습용 성능 0.60 미만	모델링 진입 전
트리 비교 판정	Δ AUC 0.02 미만이면 “선형으로 충분”	계획 단계

정확도를 주 지표로 쓰지 않은 이유를
미리 적어 두었다.

구매가 20.5%뿐이라 전부 ‘안 살 것’이라
고만 찍어도 정확도가
0.795가 나온다.

이 값은 모형의 성능이 아니라
불균형의 크기를 잴 것이다.

과적합 · 과소적합 판정선은 우리가 정한 값이다. 분류 문제에 널리 합의된 기준선이 없어 회귀에서 쓰이는 관례값을 참고해 진입 전에 확정했고, 한계에도 함께 적었다(p.41).
기준값 0.19는 혼동행렬을 제시하기 위한 값이며, 결론에서의 활용은 순위 기반이다(p.29).

민감도 대조 — 품목 제외 후에도 같은 부호와 유의성을 띠는지

설계 같은 분할 · 같은 전처리로 X 목록 한 줄만 다른 두 모델을 만든다. **모형 A = 28열 (품목 제외, 기본)** vs **모형 B = 86열 (품목 포함, 대조용)**

핵심 변수 (1차 항)	품목 제외	품목 포함	방향	유의성
담긴 시점의 가격 (price)	+0.1347	+0.1902	같음	같음
전체 조회 횟수 (prior_view_cnt)	-0.1725	-0.1727	같음	같음
그 상품 조회 횟수 (cart_product_view_cnt)	+0.7203	+0.7196	같음	같음

방향 3/3 · 유의성 3/3 → 판정 통과. 품목 제외를 확정한다.

품목 통제의 필요성 자체는 있다 — price 분산 설명력 η^2 가 품목 0.652 · 브랜드 0.552 · 조합 0.857이다. 다만 품목 묶음 (category_grp)은 어느 절단 기준에서도 표본의 약 3분의 1(32.7%)이 '기타'로 뭉치고 계층 구조도 없다. 통제 변수로 기능하지 못하기 때문에 뻔 것이지 “익명이라 해석이 안 돼서”가 아니다 — 통제 변수는 계수를 읽지 않으므로 해석 가능성은 기준이 되지 않는다. 품목 통제는 ‘기타’가 23.6%뿐인 brand_grp으로 대신했다.

다만 brand_grp의 커버율 76.4%에는 '미상' 38.85%가 포함되어, 실제 브랜드 이름이 남는 고객은 37.5%다(p.41 한계 7).

판정 규칙을 먼저 정했다.

성능 지표는 이 판정에 쓰지 않는다.

성능이 좋은 쪽을 고르는 순간 규율 위반이 된다.

다만 기록으로 남기는 것은 아래와 같다.


- 가격 계수가 +0.1347 → +0.1902로 41.1% 움직였다.
- 사전에 정한 기록선(30%)을 넘겼다.
- 교란 변수를 통제하면 계수가 작아지는 것이 전형인데 여기서 커졌다. 가격의 효과가 품목 구성에 가려져 있었다고 볼 수 있다.
- 두 조회 변수의 변화율은 0.1%로 넷째 자리에서만 갈린다.

대조군을 가장 강하게 통제한 버전(500건 기준 · 59종)으로 잡은 이유 — 여기서 결론이 바뀌지 않으면 그보다 약한 어떤 버전에서도 바뀌지 않는다.

부호·유의성은 같으나 계수 크기가 30% 이상 변한 변수가 있으면 판정은 통과로 하되 기록한다는 규칙을 미리 정해 두었다.

계수 변화율은 반올림 전 계수로 계산했다(표의 계수는 소수 넷째 자리 반올림).

트리 비교 — 비선형으로 얻을 수 있는 양의 상한



[그림] 트리 계열 - 로지스틱 회귀의 ROC-AUC 차이와 95% 구간. 붉은 선이 사전에 정한 판정 기준 0.02다

같은 분할 · 같은 변수 · 같은 조건으로 맞추고, 하이퍼파라미터를 탐색하지 않고 네 부스팅 구현 모두 동일 규제값으로 고정했다. 성능 경쟁이 아니라 “우리가 놓친 구조가 있는가”를 보는 진단이 목적이기 때문이다. 예측만이 목적이라면 부스팅이 낫지만(상위 5% 리프트 1.534 → 1.679), 본 분석은 계수를 읽어야 하므로 로지스틱을 채택했다.

모델	ROC-AUC	차이
로지스틱 회귀	0.5841	—
의사결정나무	0.5888	+0.0047
CatBoost	0.5911	+0.0071
랜덤포레스트	0.5922	+0.0081
XGBoost	0.5954	+0.0114
HistGB	0.5964	+0.0123
LightGBM	0.5969	+0.0128

최고 차이 +0.0128 < 판정 기준 0.02

부스팅 네 종이 +0.0071 ~ +0.0128 안에 모여 있어, 이 값은 특정 구현의 우연이 아니라 비선형으로 더 얻을 수 있는 양의 상한에 가깝다.

여섯 중 다섯의 구간이 0을 비켜 가므로 차이 자체는 우연이 아니다. “유의하지만 작다” — 두 문장을 함께 써야 정확하다.
트리 중요도는 다른 항을 1위로 지목한다 — price 0.4253 · 담은 그 상품 조회 0.1135. 분기 기회가 많은 연속형을 과대평가하기 때문이며, 어느 한쪽을 정답으로 삼지 않는다.

04


4. 분석 결과

4-1 모형의 신뢰성

4-2 변수 영향력



판별력 — ROC-AUC 0.5841과 기준값 0.19



[그림] 검증용 21,692명의 ROC 곡선과 혼동행렬 (기준값 0.19)


판정 방식	정밀도	재현율	F1	정확도
전부 “살 것”으로 판정	0.2050	1.0000	0.3403	0.2050
전부 “안 살 것”으로 판정	—	0.0000	0.0000	0.7950
우리 모형 (기준값 0.19)	0.2399	0.6672	0.3529	0.4985

0.5841은 무작위 판별(0.500)과 완전 판별(1.000) 사이에서 무작위 쪽에 가깝다. 이 구간에는 널리 쓰이는 등급 명칭이 없으므로 라벨을 붙이지 않고 값으로만 보고한다.

F1은 바닥값 대비 +0.013에 그친다. 정확도가 아무 판단도 하지 않는 쪽에서 더 높은 것은 p.24에서 미리 적어 둔 그대로다.

ROC-AUC 0.5841 (95% 구간 0.575 ~ 0.594) · PR-AUC 0.2609 (바닥값 0.2050) · 검증용 21,692명
예측 확률의 범위가 0.0718 ~ 0.4767로 관례적으로 쓰는 0.5를 넘는 건이 하나도 없어 기준값이 필요했고, 학습용 안에서 F1이 최대인 0.19를 채택했다. 검증용을 보고 고르면 그 순간 검증용이 오염된다.

누적 리프트 — 상위 10%에서 1.46배



[그림] 누적 리프트와 십분위별 실제 구매 비율. 점선은 각각 무작위(1.00배)와 전체 평균(20.50%)

고른 범위	인원	구매 비율	배수
상위 5%	1,084	31.46%	1.53배
상위 10%	2,170	29.86%	1.46배
상위 20%	4,339	28.42%	1.39배
상위 30%	6,508	26.43%	1.29배

예측 확률 순으로 줄을 세워 상위 10%를 고르면 구매 비율이 전체 평균 20.50%의 1.46배가 된다. 어느 장바구니를 먼저 볼지 좁히는 데에는 쓸 수 있다.

다만 **그 상위 10% 안에서도 70.1%는 사지 않는다.** 개별 고객의 구매 여부를 판정하는 용도로는 쓸 수 없다.

무작위 선택이 1.00배이고, 완벽한 모형이면 상위 10%에서 4.88배가 나온다.
십분위로 보면 3분위(22.45%)는 4분위(23.24%)보다 낮고, 8분위(14.94%)는 9분위(16.37%)보다 낮아 두 곳에서 순서가 뒤집히는데, 둘 다 신호가 약해 표본의 흔들림에 묻히는 구간으로 판단된다.

학습곡선 판정 — 과적합 없음, 신호의 한계



[그림] 학습곡선 — 학습용과 교차검증이 표본이 늘수록 가까워지며, 둘 다 0.59 부근에서 멈춘다

학습용

0.5915

교차검증 (5-fold)

0.5900

검증용


0.5841

기준	실측	임계	해당
과적합 — 학습 · 교차검증 격차 (상대)	0.25%	15% 이상	아니오
과적합 — 격차 (AUC 절대차)	0.0015	0.01 이상	아니오
과소적합 — 학습용 성능	0.5915	0.60 미만	해당 (임계값 부근)

학습용 성능이 사전 기준 0.60에 못 미치지만 임계값 부근이다.
더 유연한 부스팅도 +0.0128에 그쳤으므로(p.26),
모형이 단순해서가 아니라 신호가 약해서다.

교차검증 0.5900 ± 0.0051 (5-fold, 학습용 안에서 수행). · 더 복잡한 모형을 시도한 결과는 p.26에 있다.

표준화 계수 — 실질적으로 읽히는 상위 네 항



[그림] 표준화 계수 β_{std} 상위 10항. 기준 범주 — 브랜드 runail · 시간대 심야 · 요일 월요일

순위	조건	표준화 계수	오즈비	95% 구간
1	답은 그 상품을 몇 번 보았는가	+0.280	2.06	1.90 ~ 2.22
2	가격이 얼마인가	+0.152	1.14	1.13 ~ 1.16
3	오후에 답았는가 (심야 대비)	+0.110	1.26	1.18 ~ 1.34
4	그 밖의 조회를 얼마나 했는가	-0.109	0.84	0.80 ~ 0.88

28개 항 가운데 19개가 유의하지만 그중 10개는 표준화 계수가 0.05에도 미치지 못한다. 관측치가 86,766명이면 0.007 수준에서도 유의해지므로, **실질적으로 읽을 수 있는 항은 이 넷뿐이다.**

1위가 2위의 1.8배다.

표준화 계수 — 변수마다 단위가 달라 그대로 비교할 수 없어 같은 자로 맞춘 영향력 크기. 오즈비 — 조건이 한 단계 오를 때 구매 쪽으로 기우는 배수.
가격과 답은 그 상품 조회 횟수는 로그를 취한 값이므로, 오즈비 1.14는 "가격이 약 2.7배가 될 때", 2.06은 "(조회 수 + 1)이 약 2.7배가 될 때"로 읽는다.
순위는 1차 항 기준이며 곡선 항이 있는 두 변수는 제공항이 따로 있다. 전체 28항은 p.35~36 참고.

조회 변수 — 단독으로 볼 때와 반대인 모형 안 방향

담기 직전 30분의 전체 조회 횟수	실제 구매 비율	모형 안 확률
0회	18.54%	18.33%
1회	21.67%	16.14%
2회	22.66%	15.58%

곡선 향이 들어간 변수	꼭짓점	그 너머 고객	실제 형태
전체 조회 횟수 (prior_view_cnt)	2.94회	13.79%	U자 — 반등 구간이 실재한다
그 상품 조회 횟수 (cart_product_view_cnt)	7.15회	2명 (0.002%)	단조 — 꼭짓점이 관측 범위 밖


실제로는 조회가 늘수록 구매 비율이 오르는데, 모형 안에서는 내려간다.

원인은 포함 관계. 전체 조회수 안에 그 상품 조회수가 들어 있어(포함 100% 확인 · Spearman 0.688), 그 상품 조회수를 고정하면 전체 조회수에 남는 것은 사실상 “다른 상품을 둘러본 양”이 된다.

따라서 조회가 많을수록 구매 비율은 높아지지만, 그 효과의 대부분은 담은 그 상품을 몇 번 보았는가에서 오며, 그것을 고정하면 나머지 조회는 약 3회(꼭짓점 2.94회)까지 구매 확률을 낮추고, 그 너머(고객의 13.79%)에서는 다시 오른다.

조회가 더 많은 구간에서도 방향은 같다 — 11회 이상 25.71%.
"모형 안 확률"은 담은 그 상품 조회를 0회로 고정하고 나머지 설명변수는 학습용 평균에 둔 조건부 확률이다. 전체 조회가 0인데 그 상품 조회만 평균값인 조합은 데이터에 존재할 수 없어 이렇게 고정했으며, 집단별 실제 평균과는 다른 값이다.

예측 순위별 특징 — 구매율이 가장 낮은 집단에서 다시 늘어나는 조회량



[그림] 예측 확률 십분위별 집단의 특징 — 가격과 그 상품 조회는 단조롭게 내려가고, 전체 조회만 U자를 그린다

십분위	구매 비율	평균 가격	그 상품 조회	전체 조회
상위 10%	29.86%	35.15	1.41회	2.88회
3분위	22.45%	11.98	0.81회	1.63회
5분위	20.84%	9.41	0.32회	0.79회
7분위	16.51%	5.86	0.10회	0.57회 (최저)
하위 10%	14.52%	1.82	0.04회	1.22회 (반등)

가격과 그 상품 조회는 십분위를 따라 역전 없이 감소한다.

모형이 예측에 주로 쓰는 조건은 이 둘이다.

반면 전체 조회는 U자를 그린다.

이는 p.32에서 확인한 곡선 향이 십분위에 그대로 나타난 것이다. 다만 십분위는 그 곡선 향이 들어간 모형의 예측 확률로 나눈 것이므로, 이 그림만으로 "그런 집단이 실재한다"고 말할 수는 없다.

가격은 통화 표기가 없는 상대 단위다. 절대 금액으로 해석하지 않고 상대 비교에만 쓴다. · 모형이 가장 확신한 상위 10% 집단에서도 70.1%는 구매하지 않았다.

계수 보고표 — 표준화 계수 상위 10항

표준화 계수 내림차순 · 학습용 86,766명 · 최종 모형(곡선 항 포함 28열)

조건	실제 변수명	계수 B	표준화 계수	오즈비	p
담은 그 상품을 몇 번 보았는가	cart_product_view_cnt	+0.720	+0.280	2.06	< .001
가격이 얼마인가 (로그)	price	+0.135	+0.152	1.14	< .001
담은 시간대 · 오후 (심야 대비)	cart_timeband_오후	+0.230	+0.110	1.26	< .001
그 밖의 조회를 얼마나 했는가	prior_view_cnt	-0.173	-0.109	0.84	< .001
담은 시간대 · 오전 (심야 대비)	cart_timeband_오전	+0.189	+0.078	1.21	< .001
그 밖의 조회 (제공항)	prior_view_cnt²	+0.108	+0.074	1.11	< .001
브랜드 · italwax (runail 대비)	brand_grp_italwax	+0.432	+0.067	1.54	< .001
브랜드 · bpw.style (runail 대비)	brand_grp_bpw.style	-0.431	-0.059	0.65	< .001
담은 시간대 · 저녁 (심야 대비)	cart_timeband_저녁	+0.114	+0.054	1.12	< .001
브랜드 · masura (runail 대비)	brand_grp_masura	-0.246	-0.041	0.78	< .001

표준화 계수 상위 10항이다. 나머지 18항과 절편은 부록에 실었다. 28항 중 19개가 유의하지만 그중 10개는 표준화 계수가 0.05에 미치지 못한다 — 관측치가 8만 명대면 0.007 수준에서도 유의해지므로, 유의성만으로는 읽을 수 없다.

기준 범주 — 브랜드 runail · 시간대 심야 · 요일 월요일. 더미 계수는 전부 “기준 범주 대비”로 읽는다. · 가격은 로그를 취한 값이므로 오즈비 1.14는 “가격이 약 2.7배가 될 때”로 읽는다.

계수 보고표 부록 — 전체 28항과 절편

표준화 계수 절댓값 내림차순 · 학습용 86,766명 · 최종 모형(곡선 항 포함 28열) · 1/2 (1~14위)

변수	계수 B	표준오차	표준화 계수	오즈비	오즈비 95% 구간	p
cart_product_view_cnt_c	+0.7203	0.0399	+0.280	2.055	1.900 ~ 2.222	< .001
price	+0.1347	0.0082	+0.152	1.144	1.126 ~ 1.163	< .001
cart_timeband_오후	+0.2296	0.0338	+0.110	1.258	1.177 ~ 1.344	< .001
prior_view_cnt_c	-0.1725	0.0252	-0.109	0.842	0.801 ~ 0.884	< .001
cart_timeband_오전	+0.1889	0.0357	+0.078	1.208	1.126 ~ 1.295	< .001
prior_view_cnt_c2	+0.1083	0.0171	+0.074	1.114	1.078 ~ 1.152	< .001
brand_grp_italwax	+0.4316	0.0596	+0.067	1.540	1.370 ~ 1.730	< .001
brand_grp_bpw.style	-0.4309	0.0845	-0.059	0.650	0.551 ~ 0.767	< .001
cart_timeband_저녁	+0.1138	0.0342	+0.054	1.121	1.048 ~ 1.198	< .001
brand_grp_masura	-0.2455	0.0661	-0.041	0.782	0.687 ~ 0.891	< .001
brand_grp_irisk	-0.1792	0.0540	-0.039	0.836	0.752 ~ 0.929	< .001
cart_product_view_cnt_c2	-0.1997	0.0603	-0.036	0.819	0.728 ~ 0.922	< .001
cart_weekday_토	-0.0773	0.0322	-0.027	0.926	0.869 ~ 0.986	.016
cart_weekday_일	-0.0760	0.0330	-0.025	0.927	0.869 ~ 0.989	.021

기준 범주 — 브랜드 runail · 시간대 심야 · 요일 월요일. 더미 계수는 전부 “기준 범주 대비”로 읽는다. · _c 는 중심화한 값, _c2 는 그 제곱항이다. · 가격과 담은 그 상품 조회 횟수는 로그를 취한 값이므로 오즈비는 “값이 약 2.7배가 될 때”로 읽는다.

계수 보고표 부록 — 전체 28항과 절편

표준화 계수 절댓값 내림차순 · 학습용 86,766명 · 최종 모형(곡선 항 포함 28열) · 2/2 (15~28위와 절편)

변수	계수 B	표준오차	표준화 계수	오즈비	오즈비 95% 구간	p
brand_grp_ingarden	-0.1929	0.0783	-0.025	0.825	0.707 ~ 0.961	.014
brand_grp_concept	+0.1595	0.0648	+0.023	1.173	1.033 ~ 1.332	.014
brand_grp_estel	+0.1362	0.0587	+0.023	1.146	1.021 ~ 1.286	.020
brand_grp_jessnail	-0.1710	0.0781	-0.021	0.843	0.723 ~ 0.982	.029
cart_weekday_수	+0.0564	0.0317	+0.019	1.058	0.994 ~ 1.126	.076
brand_grp_cnd	+0.1398	0.0693	+0.019	1.150	1.004 ~ 1.317	.044
brand_grp_kapous	+0.0808	0.0627	+0.013	1.084	0.959 ~ 1.226	.197
brand_grp_uno	+0.0837	0.0654	+0.012	1.087	0.956 ~ 1.236	.201
cart_weekday_목	+0.0304	0.0312	+0.011	1.031	0.970 ~ 1.096	.330
brand_grp_기타	-0.0241	0.0393	-0.010	0.976	0.904 ~ 1.054	.540
cart_weekday_화	+0.0255	0.0319	+0.009	1.026	0.964 ~ 1.092	.425
brand_grp_미상	+0.0049	0.0375	+0.002	1.005	0.934 ~ 1.081	.897
brand_grp_gratto1	-0.0097	0.0537	-0.002	0.990	0.891 ~ 1.100	.856
cart_weekday_금	+0.0031	0.0304	+0.001	1.003	0.945 ~ 1.065	.920
절편 (const)	-1.7635	—	—	—	—	—

28항 중 19항이 $\alpha = 0.05$ 에서 유의하다. 유의하지 않은 9항은 요일 4개(수 · 목 · 화 · 금)와 브랜드 5개(kapous · uno · 기타 · 미상 · gratto1)다.

유의한 19항 중에서도 10항은 표준화 계수가 0.05에 미치지 못한다 — 관측치가 8만 명대면 0.007 수준에서도 유의해지기 때문이다.

기준 범주 — 브랜드 runail · 시간대 심야 · 요일 월요일. 더미 계수는 전부 “기준 범주 대비”로 읽는다. · _c 는 중심화한 값, _c2 는 그 제곱항이다. · 가격과 담은 그 상품 조회 횟수는 로그를 취한 값이므로 오즈비는 “값이 약 2.7배가 될 때”로 읽는다.

05

5. 결론

5-1 질문별 답변

5-2 의의와 시사점

5-3 한계



연구 질문 — 개별 판정 불가, 상위 10% 선별 유효

장바구니에 담은 시점에 알 수 있는 정보만으로 담은 그 상품의 7일 내 구매 여부를 얼마나 분류할 수 있으며, 그 분류에 가장 크게 기여하는 조건은 무엇인가

얼마나 구분할 수 있는가

예측 모형으로는 쓸 수 없다. ROC-AUC 0.584는 무작위 판별(0.500)에 가깝고, 모형이 가장 확신한 상위 10% 집단에서도 70.1%가 구매하지 않는다. 개별 고객의 구매 여부를 판정하는 용도로는 성능이 부족하다.

다만 순위를 매기는 용도로는 유효하다. 상위 10%의 구매 비율은 29.86%로 전체 평균 20.50%의 1.46배다. 어느 장바구니를 먼저 볼지 좁히는 데에는 쓸 수 있다.

무엇이 가장 크게 기여하는가

순위	조건	실제 관측값
1	담은 그 상품을 담기 직전 30분에 몇 번 보았는가	0회 17.74% → 4회 이상 34.73%
2	가격이 얼마인가	최저 5분위 16.48% → 최고 5분위 26.58%
3	담은 시간대	심야 17.78% / 오후 21.80%
4	그 밖의 조회를 얼마나 했는가 (음의 방향)	그 상품 조회를 고정했을 때만 음의 방향 — 단독으로는 반대다 (p.32)

1위와 2위의 표준화 계수 차이는 1.8배로, 담은 그 상품을 몇 번 보았가가 로지스틱 모형 안에서 가장 크게 기여한다

순위는 로지스틱 표준화 계수(1차 항) 기준이며, 오른쪽은 그에 대응하는 원자료 관측값이다.
트리 중요도에서는 가격이 1위(0.4253)이고, 3위인 담은 시간대는 '오후(심야 대비)' 한 더미의 값이다(p.26 · p.31 · p.34).

가정 수정 — 5가지 검토 중 방향만 유지

처음 가정 조회 행동이 구매 전환에 영향을 미친다

담기 직전에 여러 번 본 고객은 그렇지 않은 고객보다 구매로 이어질 확률이 높다.

차이 자체는 뚜렷하다 — 0회 17.74% 대비 2회 이상 28.84%로 11.1%p(1.6배)다.

다만 해당 고객이 5.6%뿐이고 44.7%는 조회 기록이 없어 전체 판별력으로는 이어지지 않는다.

“조회 행동”을 “담은 그 상품을 본 횟수”로 좁히고, “영향을 미친다”를 “전환을 예고한다”로 바꾼 것이다. 조회 횟수를 구매 의향의 신호로 쓰는 데에는 인과관계가 필요하지 않다. 신호로만 쓰는 한 이 결론은 그대로 활용할 수 있다.

①은 가정을 그대로 지지한다. 그러나 ②~⑤ 네 군데에서 무너지므로, 이렇게 좁혀야 다섯 가지 모두와 충돌하지 않는다.

①은 그대로 유지, ②~⑤가 좁힌 이유

1

방향은 가정대로다 — 여기는 유지된다

0회 17.74% → 4회 이상 34.73%. 역전 없음

2

그러나 “조회 행동”을 하나로 묶으면 주장이 무너진다

두 방향으로 갈라져 상쇄된다 (p.32)

3

조회 행동만의 묶이 크지 않다

조회 2종만으로 0.5613, 가격·브랜드만으로 0.5619로 사실상 같다.
두 조회 변수는 모형 판별력 향상분의 약 20%를 맡는다

4

절반 가까이에는 아예 적용되지 않는다

담기 직전 30분에 조회 기록이 없는 고객이 44.7%

5

관측 데이터이므로 인과가 아니다

조회가 구매를 낳았는지, 애초의 구매 의향이 둘을 함께 낳았는지 가를 수 없다

두 조회 변수를 모형에서 빼면 전체 판별력이 0.5827에서 0.5661로 떨어진다. 무작위(0.5)보다 나은 몫 0.0827 가운데 0.0166이 사라지는 것이므로, 두 변수는 모형 판별력 향상분의 약 20%를 맡는다.

0.5827 · 0.5661 · 0.5613 · 0.5619는 곡선 향을 넣기 전 26열 기준 모형의 값이고, 본문의 0.5841은 곡선 향을 포함한 28열 최종 모형의 값이다.

실무 적용 — 개입 신호 다섯 가지와 시점·효과의 제약

발견	활용
담은 그 상품을 2회 이상 본 고객의 구매 비율 28.84% (6,071명 · 전체의 5.6%)	담기 직전 반복 조회를 개입 신호로 삼는다. 규모가 작아 정밀 타킷에 적합하다. 1회 이상으로 넓히면 41,968명(38.7%)이 대상이 되고 구매 비율은 24.88%로 낮아진다.
그 상품 조회를 같게 놓으면 전체 조회량이 많은 장바구니가 오히려 덜 전환된다	그 상품 조회를 고정했을 때 약 3회까지는 전체 조회량이 많을수록 덜 전환된다. 그 범위에서만 신호로 쓰지 않는다 (p.32)
최고 가격 5분위 26.58%, 최저 5분위 16.48%	저가 상품을 담은 경우 7일 내 같은 상품 구매 비율이 낮다. 가격 자체의 효과인지 품목 차이인지 가를 수 없어(η^2 품목 0.652, p.25), 개입 전에 같은 품목 안에서 가격대별로 다시 확인한다
브랜드별 구매 비율 12.09% ~ 28.46%	구매 비율이 낮은 브랜드(bpw.style · irisk · masura)의 상세 페이지와 가격 구성을 우선 점검한다. 다만 가격을 통제하면 브랜드의 영향력이 4위권 밖으로 밀리므로, 차이의 상당 부분은 취급 가격대의 차이일 수 있다
심야 17.78%, 오후 21.80%	심야에 담긴 장바구니가 가장 덜 전환된다

시책으로 옮길 때 — 담기 직후, 할인이 아닌 안내

구매의 63.57%가 1시간 안에 일어난다. 알림이 1시간 뒤에 나가면 그 사이 이미 구매한 고객은 대상이 아니며, 검증용 21,692명 가운데 1시간 뒤에도 사지 않은 18,866명으로 다시 측정하면 배수가 1.46배에서 1.20배로 떨어진다.

그런데 이 모형은 구매 가능성을 찾는 모형이지 개입 효과를 찾는 모형이 아니어서, 담기 직후에 할인을 주면 어차피 살 고객에게 마진을 소모하게 된다. 그래서 담기 직후에는 할인이 아니라 비금전적 안내(재고 · 배송 정보)로 한정한다. 개입의 실제 효과는 별도의 실험으로 확인해야 한다.

이 결과의 사용자를 스토어의 상품 진열 · 가격 정책 담당자와 고객 대상 마케팅(CRM) 담당자로 정하고 활용 방안을 적었다.

비용·마진 자료가 없어 손익은 계산할 수 없다. 다만 1시간 뒤 재측정에서 배수가 1.20배로 떨어지는 점을 고려하면 건당 비용이 드는 쿠폰·메일의 효과는 기대하기 어려우므로, 추가 비용이 들지 않는 담기 직후 화면 노출에 한정하는 것이 타당하다.

한계 정리 — 기록으로 남긴 열세 가지

#	한계
1	다른 상품을 구매한 고객이 미구매로 기록된다 — 미구매 86,222명 중 6,460명(7.49%). 나머지 92.51%는 같은 기간에 다른 상품도 사지 않았다. 이후 재방문 구매 가능성은 확인하지 않았다
2	7일을 넘겨 구매한 고객도 미구매로 기록된다 — 담은 그 상품을 결국 구매한 24,109명 중 1,873명(7.77%)이 여기에 해당한다
3	시간대 보정이 추정이다 — 제공처가 시간대를 밝힌 문서가 없어 활동 분포의 모양으로 추정했으며, 곡선만으로는 +2와 +3을 구분하지 못한다
4	관측 초기 제외 경계가 판단이다 — 경계는 일별 담기 인원이 평상시 수준으로 내려오는 첫날로 정했다(p.11). 제외 집단의 재담기율(제외된 고객이 담은 뒤 7일 안에 다시 담은 비율)은 평상시의 1.14배로, 사전 기준(1.3 이상 지지 / 1.1 미만 기각)에서 '보류'로 판정됐다
5	조회 여부 변수의 제외가 0.49%p 차이로 갈렸다 — 표본이 조금만 달랐다면 반대로 결정될 수 있었다
6	로그 변환은 분포 모양 때문이 아니라 소수의 극단값(조회 최대 71회 · 가격 327.78)이 계수를 좌우하는 것을 줄이려고 적용했다. 그 대신 계수를 로그 단위로 읽어야 하는 부담이 남는다
7	품목을 제외했을 때 가격 계수가 41.1% 움직였다 — 방향과 유의성은 같았으나 품목 통제가 불완전하다. 대신 넣은 brand_grp도 '미상'이 38.85%라 실제 브랜드 이름이 남는 고객은 37.5%뿐이다. 따라서 가격의 방향을 인과로 진술하지 않는다
8	담은 시간대가 3위인데 해석이 불분명하다 — 담기 전 행동도 상품 조건도 아니며, 유입 경로나 기기의 대리 지표일 가능성이 있으나 데이터로 확인할 수 없다
9	고객당 최초 장바구니 1건만 관찰하므로 재방문 · 반복 구매 고객의 행동은 분석 범위 밖이다
10	품목 이름의 결측이 98.32%여서 상품 카테고리의 의미 해석이 제한된다
11	구간 경계 · 단조성 허용폭 · 공통 눈금 · 포함관계 규칙 · 담은 시간대의 시각 경계 · 과적합·과소적합 판정선은 널리 합의된 기준이 없어 우리가 정한 값이다. 구간 경계는 목표변수와 무관한 다른 분석에서 이미 확정된 것을 재사용해, 결과를 보고 경계를 고르지 않았음을 확보했다
12	검증용이 같은 기간의 무작위 분할이라, 다른 기간(예: 다음 달)에도 성능이 유지되는지는 확인하지 않았다 (p.20)
13	대상이 러시아로 추정되는 화장품 스토어 한 곳이라 다른 업종 · 다른 스토어로 일반화하지 않는다 (p.7)

판정이 필요한 한계는 기준을 결과보다 먼저 정했고, 정하지 못한 것은 정하지 못했다고 기록했다. 8 · 9 · 10은 설계에서 비롯된 제약이다. 예측력 자체의 한계는 p.30에서 다루었다

데이터 · 분석 도구 · 산출물

데이터

출처
REES46 Marketing Platform (Michael Kechinov)

데이터셋
Kaggle — ecommerce-events-history-in-cosmetics-shop
(<https://www.kaggle.com/datasets/mkechinov/ecommerce-events-history-in-cosmetics-shop>)

사용 파일
2019-Oct.csv · 2019-Nov.csv 전체 5개 중 2개

라이선스
캐글 공개 데이터셋

분석 도구

실행 환경
Python 3 · Jupyter Notebook

데이터 처리
pandas · numpy

통계 · 모형
statsmodels · scipy

기계학습
scikit-learn · xgboost · lightgbm · catboost

시각화
matplotlib · seaborn

산출물 | 노트북 15단계

- 01 데이터 품질 점검
- 02 전제 검증
- 03 분석 대상 테이블
- 04 설명변수 생성
- 05 목표변수 생성
- 06 범주 묶기 기준
- 07 관측 초기 구간 진단
- 08 마스터 테이블
- 09 단변량 분석
- 10 이변량 분석
- 11 다변량 분석 → 변수 선택
- 12 모델링용 전처리
- 13 모델 구축
- 14 교차검증 · 트리 비교 · 해석
- 15 보고서 그림